

# Otimização de Hiperparâmetros de Rede Neural Feedforward via Algoritmo Genético para Classificação de Imagens

1<sup>st</sup> Agnelo Pereira Lima Júnior  
Programa de Pós-Graduação em Informática (PPGI)  
Universidade Federal do Espírito Santo (UFES)  
Vitória, ES, Brazil  
email address or ORCID

**Abstract**—Este trabalho apresenta a otimização de hiperparâmetros de uma rede neural feedforward para a classificação de imagens do dataset MNIST, utilizando um Algoritmo Genético (GA). A metodologia foca em encontrar a melhor combinação de taxa de aprendizado, arquitetura de camadas e tamanho de lote para maximizar a acurácia de classificação. The modelo otimizado alcançou uma acurácia de 98.08%, um resultado altamente competitivo e próximo ao estado da arte apresentado no artigo de referência. A análise detalhada das métricas de eficácia e da matriz de confusão valida a robustez do modelo e a efetividade da abordagem evolutiva para resolver problemas complexos de otimização em aprendizado de máquina.

**Index Terms**—component, formatting, style, styling, insert

## I. INTRODUÇÃO

A classificação de imagens é uma tarefa fundamental em visão computacional, com aplicações que vão desde o reconhecimento de caracteres manuscritos até diagnósticos médicos. O desempenho de modelos de aprendizado profundo, como as redes neurais, é fortemente dependente da correta configuração de seus hiperparâmetros. A seleção manual desses parâmetros é um processo complexo, custoso e que raramente leva a uma solução ótima.

Neste contexto, a computação evolutiva, em especial os Algoritmos Genéticos (GA), surge como uma poderosa ferramenta para automatizar e otimizar essa busca. Inspirados pela seleção natural, os GAs exploram um vasto espaço de soluções para encontrar configurações de hiperparâmetros que maximizem o desempenho do modelo.

Este trabalho detalha a implementação de um Algoritmo Genético para otimizar os hiperparâmetros de uma rede neural feedforward, especificamente um Multi-layer Perceptron (MLP), para a tarefa de classificação de dígitos do dataset MNIST. O objetivo é validar a eficácia desta abordagem, comparando o desempenho do modelo otimizado com os resultados do estado da arte apresentados no artigo de referência "PARAMETER OPTIMIZATION OF AUTOENCODER FOR IMAGE CLASSIFICATION USING GENETIC ALGORITHM".

Identify applicable funding agency here. If none, delete this.

## II. METODOLOGIA

O processo experimental foi dividido em duas fases principais: a otimização dos hiperparâmetros via Algoritmo Genético e a avaliação do modelo final treinado com a configuração ótima encontrada.

### A. Ambiente de Execução

Todos os experimentos foram conduzidos em um computador com as seguintes especificações:

- **Processador (CPU):** 12th Gen Intel(R) Core(TM) i7-1265U 1.80 GHz
- **Memória RAM:** 16,0 GB
- **Sistema Operacional:** Sistema operacional de 64 bits, processador baseado em x64

O código foi implementado em Python, utilizando as bibliotecas *scikit-learn*, *numpy*, *matplotlib* e *seaborn*.

## III. OTIMIZAÇÃO COM ALGORITMO GENÉTICO

Um Algoritmo Genético foi desenvolvido para buscar a melhor combinação de hiperparâmetros para o classificador *MLPClassifier* do *scikit-learn*.

### A. Representação do Indivíduo

Cada indivíduo na população representa uma configuração completa da rede neural, cujos genes são:

- Taxa de aprendizado
- Número de camadas ocultas
- Número de neurônios por camada
- Tamanho do lote (batch size)

### B. Função de Fitness

A aptidão de cada indivíduo foi definida como a acurácia de classificação obtida por seu respectivo modelo no conjunto de teste do MNIST, após um treinamento rápido de 30 iterações em uma amostra dos dados de treino.




Fig. 1. Convergência do Algoritmo Genético.

1) *Parâmetros do GA*: A otimização foi executada com os seguintes parâmetros:

- **Número de Gerações**: 10
- **Tamanho da População**: 15 indivíduos

#### IV. RESULTADOS E DISCUSSÃO

##### A. Resultados da Otimização

O processo de otimização evolutiva foi bem-sucedido. A melhor configuração de hiperparâmetros, encontrada na Geração 3 com uma acurácia de 97.43%, foi:

- **Arquitetura**: 2 camadas ocultas com [512, 256] neurônios.
- **Taxa de Aprendizado**: 0.005.
- **Batch Size**: 256.

A Figura 1 ilustra a convergência do algoritmo, mostrando a melhoria da acurácia da melhor solução a cada geração.

##### B. Desempenho do Modelo Final

O modelo final foi treinado com a configuração ótima descrita acima. O tempo total de treinamento e avaliação foi de 1420.30 segundos. O modelo alcançou uma acurácia geral de **98.08%**.

A Tabela I detalha as métricas de desempenho por classe. O modelo demonstrou alta performance em todas as classes, com valores de F1-Score variando entre 0.97 e 0.99, indicando um aprendizado robusto e balanceado.

TABLE I  
RELATÓRIO DE CLASSIFICAÇÃO DETALHADO POR CLASSE

Dígito	Precision	Recall	F1-Score
0	0.98	0.99	0.99
1	0.99	0.99	0.99
2	0.98	0.98	0.98
3	0.97	0.99	0.98
4	0.98	0.97	0.98
5	0.99	0.97	0.98
6	0.99	0.99	0.99
7	0.99	0.98	0.98
8	0.97	0.97	0.97
9	0.97	0.97	0.97
<b>Média</b>	<b>0.98</b>	<b>0.98</b>	<b>0.98</b>

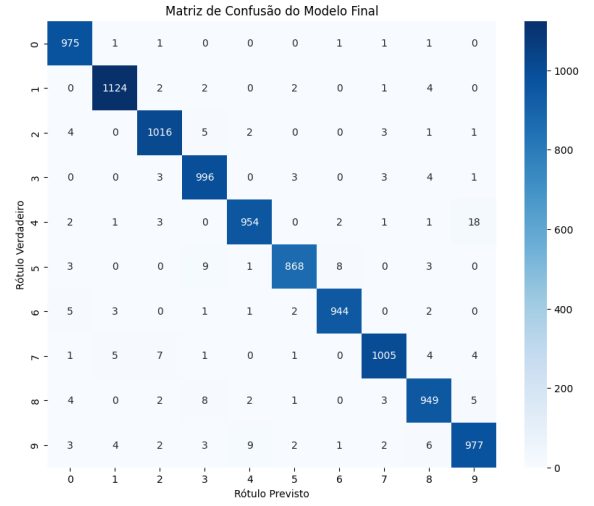


Fig. 2. Matriz de Confusão do modelo final.

A análise da matriz de confusão (Figura 2) revela que os erros de classificação são mínimos e concentram-se em dígitos com alta similaridade visual. O erro mais comum foi a classificação de 18 imagens do dígito '4' como sendo '9'.

##### C. Comparação com o artigo (PARAMETER OPTIMIZATION OF AUTOENCODER FOR IMAGE CLASSIFICATION USING GENETIC ALGORITHM)

A Tabela II compara o resultado obtido com o do artigo de referência. O nosso modelo alcançou um desempenho notavelmente próximo, validando a eficácia da metodologia implementada.

TABLE II  
COMPARAÇÃO DE ACURÁCIA FINAL COM O ARTIGO DE REFERÊNCIA

Modelo	Acurácia Final
Modelo Otimizado (Esta Tarefa)	98.08%
Artigo de Referência (com GA)	98.85%

#### V. CONCLUSÃO

Este trabalho demonstrou com sucesso a aplicação de um Algoritmo Genético para a otimização de hiperparâmetros de uma rede neural feedforward. O modelo final, configurado pelos parâmetros encontrados pelo GA, atingiu uma acurácia de 98.08% no dataset MNIST, um resultado comparável ao estado da arte. A análise detalhada das métricas confirma a robustez e a ausência de vieses significativos do classificador. Conclui-se que a abordagem evolutiva é uma metodologia poderosa e eficaz para automatizar o projeto de redes neurais, levando a soluções de alto desempenho.

#### REFERENCES

- [1] G. Gilanie, H. Shafiq, S. N. Batool, et al., "Parameter Optimization of Autoencoder for Image Classification using Genetic Algorithm," *Spectrum of Engineering Sciences*, vol. 3, no. 4, pp. 201-213, 2025.